주식 가격변동 예측
LSTM과 CV 모델 성능 비교

기초 CV3팀
노승현, 정재원, 현진명

BACKGROUND

STOCK CHART ANALYSIS

- 일반적으로 주가 예측에는 시계열 기반의 LSTM 모델이 가장 많이 사용되지만,
  실제 금융에서 패턴 중심의 그래프 분석이 널리 쓰인다는 점에 착안하여
  이미지 기반 CV 모델을 사용하면, LSTM이 놓칠 수 있는 패턴 정보를 포착할 수 있을 것이라 기대함

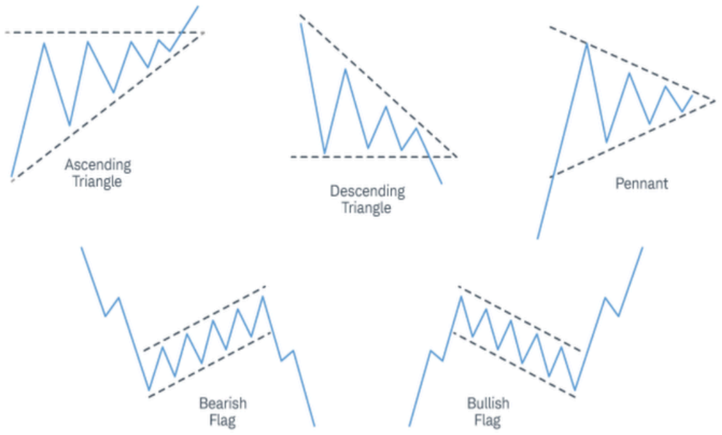

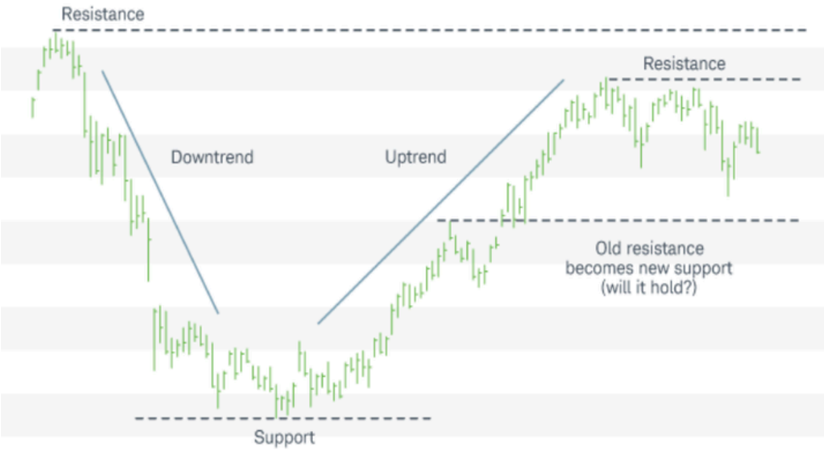

RELATED WORK

STOCK PRICE PREDICTION: WHY LSTM?

- 기존 접근방식의 한계점

① REGRESSION ON CROSS-SECTIONAL DATA

- 특정 시점의 데이터에 대해 단순 회귀로 주가를 예측하는 방식
- 비선형적인 주가 데이터와 복잡한 시장 패턴을 파악하기 어려움

② TIME SERIES + ECONOMETRIC TECHNIQUES

- ARIMA, VAR, ARDL, QUANTILE REGRESSION 등
- 강력한 가정을 필요로 하는 모델이 많은데, 실제 금융시장에서는 이러한 가정이 깨지기 쉬움

③ LEARNING-BASED (ML, DL, NLP) APPROACHES

- OVERFITTING 문제 & 기본 RNN은 GRADIENT VANISHING 문제가 있음

(MEHTAB S, SEN J, DUTTA A. 2020)

RELATED WORK

STOCK PRICE PREDICTION: WHY LSTM?

- LSTM 모델은 CELL STATE의 도입으로 필요한 정보를 오랫동안 기억했다가 적절한 시점에 꺼내 사용할 수 있기 때문에 시계열 데이터를 다루기에 좋다!

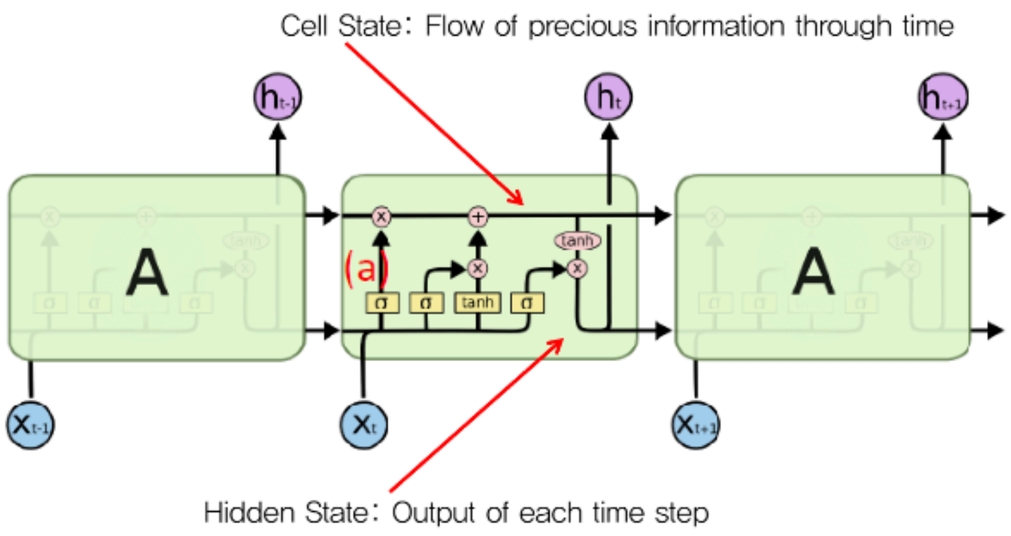

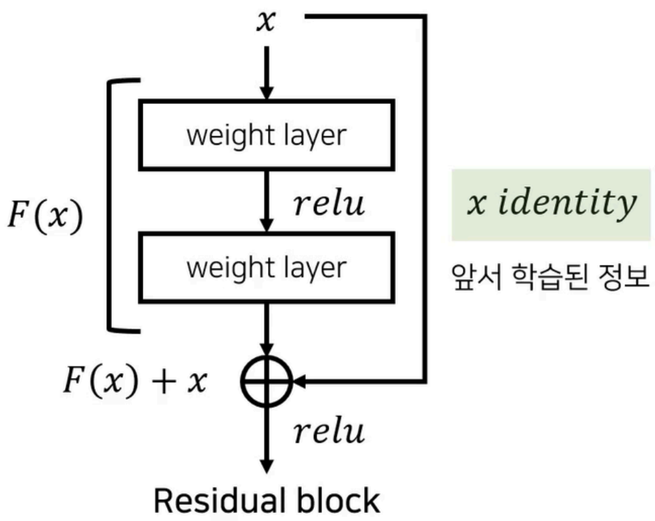

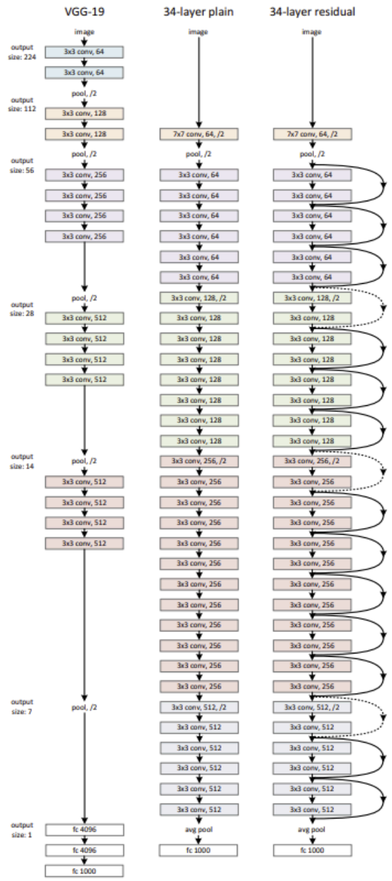

(HE K, ZHANG X, REN S, SUN J. 2016)

RELATED WORK

FINANCIAL VISION

ALGORITHMIC FINANCIAL TRADING WITH DEEP CONVOLUTIONAL NEURAL NETWORKS: TIME SERIES TO IMAGE CONVERSION APPROACH (SEZER, 2018)

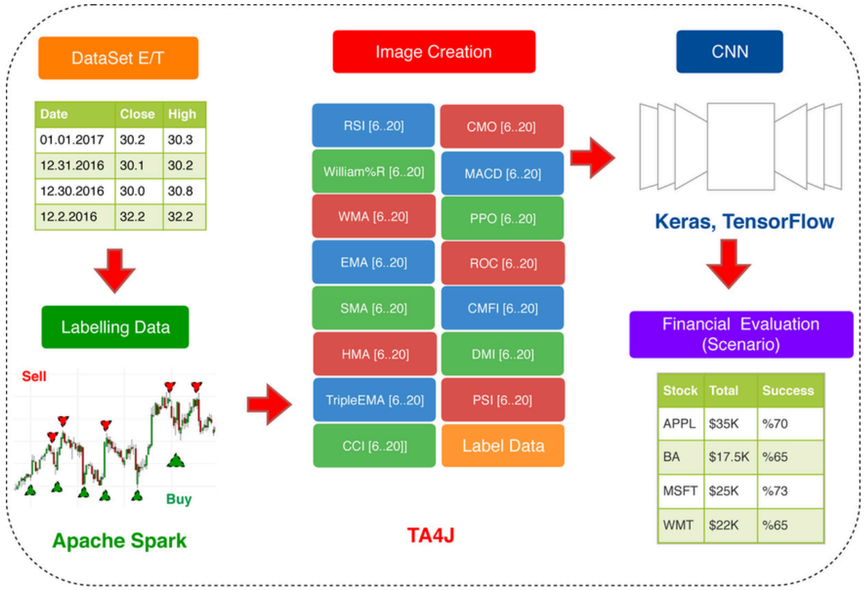

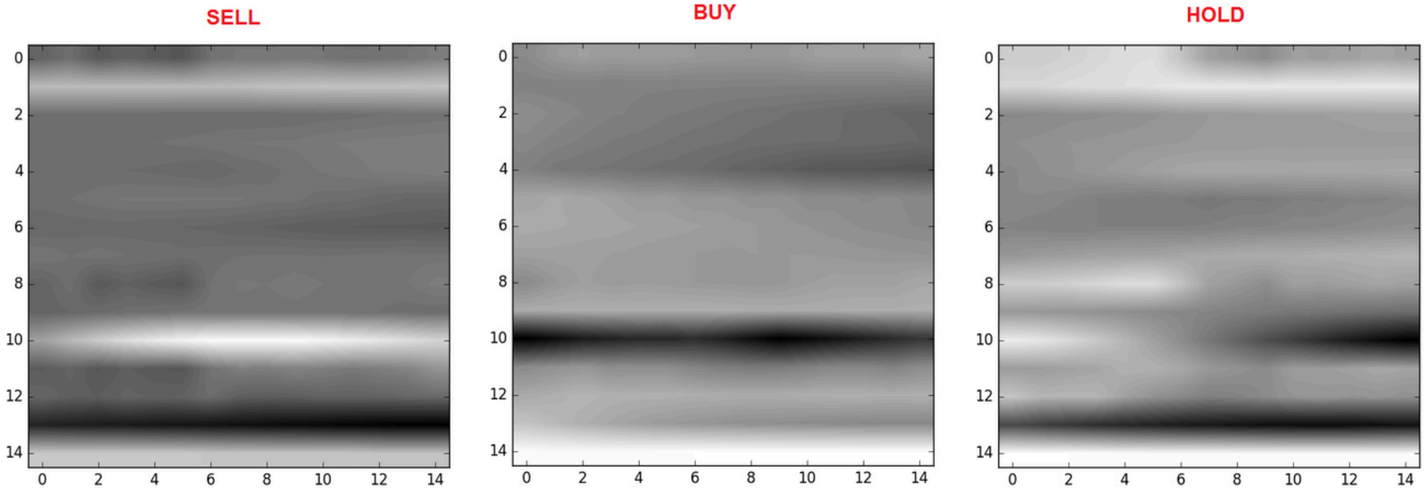

(SEZER OB, OZBAYOGLU AM. APPLIED SOFT COMPUTING. 2018)

PIPELINE

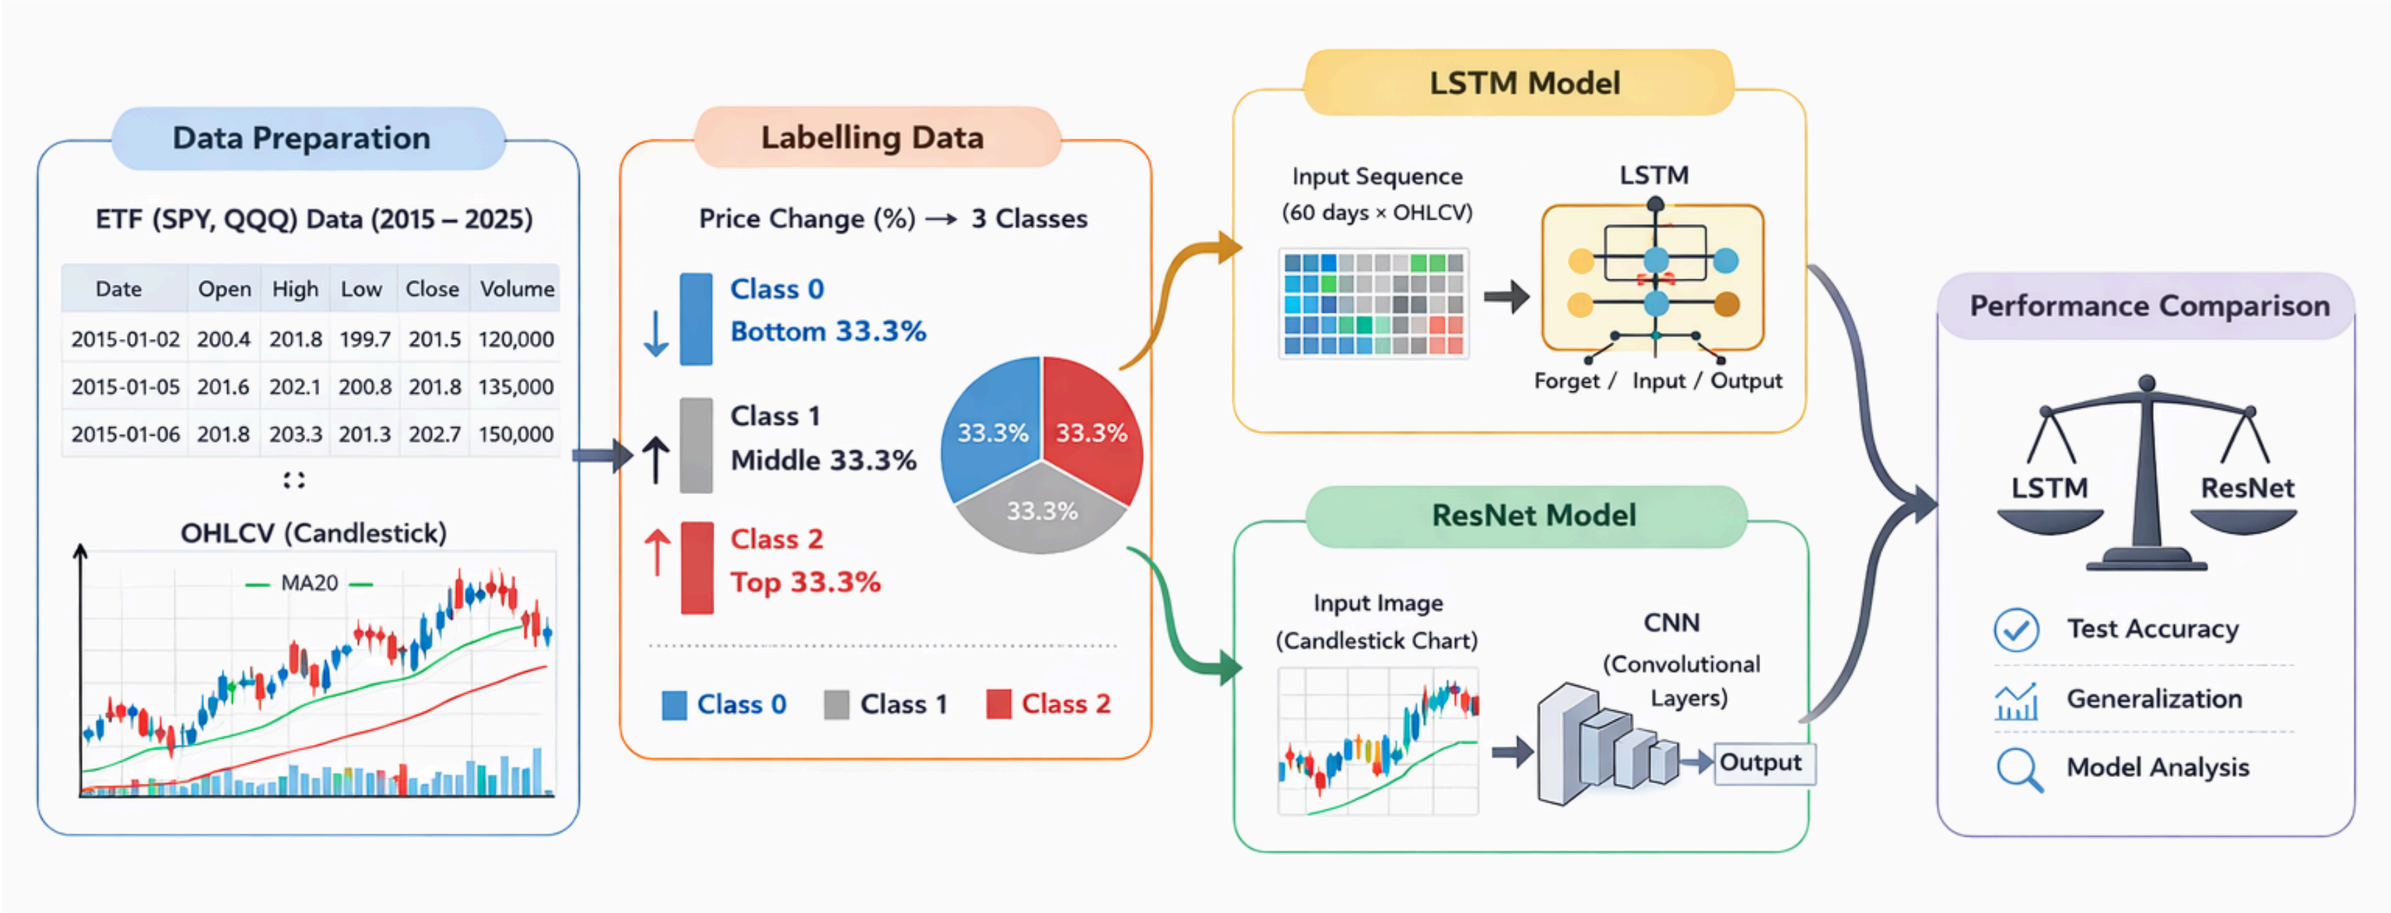
Data Preparation
ETF (SPY, QQQ) Data (2015 – 2025)
Date Open High Low Close Volume
2015-01-02 200.4 201.8 199.7 201.5 120,000
2015-01-05 201.6 202.1 200.8 201.8 135,000
2015-01-06 201.8 203.3 201.3 202.7 150,000
OHLCV (Candlestick)
MA20
Labelling Data
Price Change (%) → 3 Classes
Class 0
Bottom 33.3%
Class 1
Middle 33.3%
Class 2
Top 33.3%
33.3%
33.3%
33.3%
Class 0
Class 1
Class 2
LSTM Model
Input Sequence
(60 days × OHLCV)
LSTM
Forget / Input / Output
ResNet Model
Input Image
(Candlestick Chart)
CNN
(Convolutional
Layers)
Output
Performance Comparison
LSTM
ResNet
Test Accuracy
Generalization
Model Analysis

DATA PREPARATION

1차 실험

- NVIDIA 주가 데이터 (학습기간 5년, TRAIN 4년, TEST 1년)
- SLIDING WINDOW (20일, 약 한 달)
- DATA LABELLING (CLASS 0~4)
  - 주가 상승/하락 비율을 계산하여 수익률에 따라 5가지 그룹으로 분류
  - REGRESSION이 아닌 CLASSIFICATION TASK

- PROBLEM: 모델이 학습을 진행할수록 후반부 EPOCH에서 수학적으로 패턴을 찾는 대신 TRAIN SET에 가장 많이 분포해 있는 CLASS로 전부 찍어버림

DATA PREPARATION

2차 실험

정답 LABELLING 방식 & 학습기간을 다르게 조정하며 실험을 진행함

PROBLEM: 시계열 기반 LSTM 모델이 초반에는 다양한 CLASS를 예측하지만, 후반부에는 정답률 향상을 위해 하나의 정답만 선택함

→

SOLUTION:

① 0 (하위 30%), 1 (상위 30%)
→ 데이터셋 노이즈를 제거함

② 3-CLASS 구조 (33.3%씩)

③ 0 (평균 이하), 1 (평균 이상)

DATA PREPARATION

2차 실험

- ETF (SPY, QQQ) 데이터 - 학습기간 10년 (2015.01.01 ~ 2025.01.01)
- TRAIN 8년 (2015.01.01 ~ 2023.01.01), TEST 2년 (2023.01.01 ~ 2025.01.01)
- SLIDING WINDOW (60일, 약 한 분기)
- OHLCV (시가, 고가, 저가, 종가, 거래량) & 이동평균선(20일, 60일)을 활용함

- DATA LABELLING (CLASS 0~2)
  - 수익률에 따라 3가지 그룹으로 분류
  - CLASS 0: 하락장 (하위 33.3%), CLASS 1: 보합장 (중위 33.3%), CLASS 2: 상승장 (상위 33.3%)

$$\text{수익률} = \frac{T + 20\text{일의 종가}}{T\text{일의 종가}} - 1$$

$$T : 60\text{일 } Window\text{의 마지막 날}$$

DATA PREPARATION

2차 실험

- SLIDING WINDOW:
  긴 시계열 데이터를 일정 길이의 짧은 구간 (WINDOW)으로 잘라서, 각 구간을 몇 칸씩 (STRIDE) 이동시키며 학습하는 방식

- RESNET DATASET:
  우측과 같이 CANDLESTICK 그래프 형태로 변환하여 이미지 데이터를 생성함

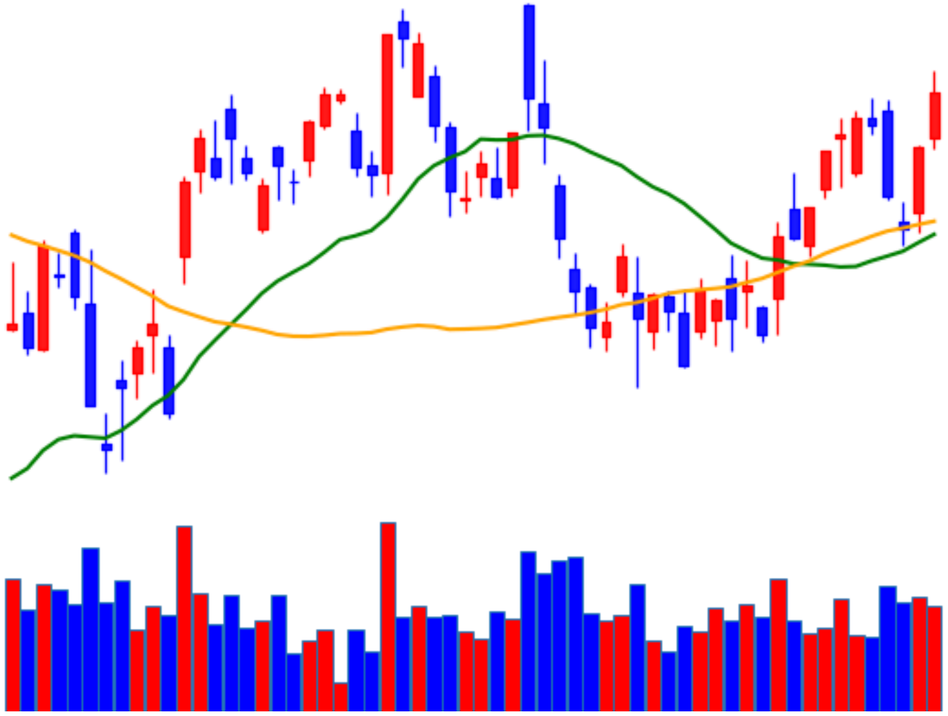

EXPERIMENTS

LSTM

데이터: NPY 파일 형태로 TRAIN SET과 TEST SET을 생성함

파라미터 튜닝:

- 'EPOCHS': [40],
- 'BATCH_SIZE': [32, 64],
- 'DROPOUT': [0.1, 0.3],
- 'LR': [0.001, 0.0005],
- 'WEIGHT_DECAY': [1E-5, 0.0],
- 'HIDDEN_DIM': [64, 128],
- 'NUM_LAYERS': [1, 2]

실험 결과:

- 최고 성능: 약 43% ~ 45% TEST ACCURACY
- 학습 특징: TRAIN ACC가 55~60%에서 안정적으로 멈췄고, TEST ACC와의 격차가 12~15% 수준으로 유지됨 → 데이터를 '단순 암기'하지 않고 패턴을 '추론'한 것으로 보임
- 주요 파라미터: BATCH SIZE 64, L2 NORM은 없거나(0.0) 작게(1E-05) 주는 것이 유리했음

EXPERIMENTS

RESNET

데이터: CANDLESTICK 이미지 형태 (MPLFINANCE 라이브러리 활용)

파라미터 튜닝:

- 'EPOCHS': [40],
- 'BATCH_SIZE': [32, 64],
- 'DROPOUT': [0.1, 0.3],
- 'LR': [1E-4, 5E-5],
- 'WEIGHT_DECAY': [1E-5, 0.0],
- 'MODEL_DEPTH': [18, 34]

실험 결과:

- 최고 성능: 약 39% ~ 41% TEST ACCURACY
- 학습 특징: 모든 모델의 TRAIN ACC가 99% ~ 100%를 기록 → CNN 특성상 수천 장의 주식 차트를 아주 빠른 속도로 외워 버렸기 때문 → 새로운 TEST 데이터에서는 40% 부근의 성적
- 주요 파라미터: RESNET18 < RESNET34, 과적합을 막기 위해 DROPOUT 0.3 등 강한 규제가 들어가는 것이 유리했음

CONCLUSION

LSTM 모델과 RESNET 모델의 비교

구분	LSTM (실험 52번)	ResNet34 (실험 26번)
데이터 형태	순차적 수치 배열 (시계열)	캔들스틱 차트 (이미지)
학습률 (LR)	0.001	0.0001
최적 달성 Epoch	10	25
Train Accuracy	56.80%	100.00%
Test Accuracy	43.85%	41.22%
Generalization Gap	약 13% (안정적)	약 59% (심각한 과적합)

RESNET 모델의 한계점:

① TRAIN ACCURACY를 보면 OVERFITTING이 발생했다고 판단할 수 있음

② 주가 데이터는 본질적으로 시계열 데이터이기 때문에 이를 CANDLESTICK으로 변환하면 노이즈가 발생할 수 밖에 없음

LIMITATIONS

01 OHLCV와 이동평균선만으로는 실제 시장의 모든 변수를 고려할 수 없음
→ 실제 주가에 결정적인 영향을 미치는 거시적인 경제지표(금리, 환율),
기업의 호재/악재 뉴스, 투자자들의 공포/탐욕 지수 등이 반영되지 않음

02 시간과 자원의 부족으로 학습 데이터셋의 크기를 무작정 늘릴 수 없었고,
PARAMETER TUNING도 다양하게 진행하지 못한 점이 아쉬움

FUTURE WORK

01 데이터 확장: 자연어 처리(NLP)를 도입하여 경제 뉴스 및 센티먼트 분석까지 결합한다면, 본 실험의 한계를 극복하고 훨씬 유의미한 모델을 만들 수 있을 것으로 기대됨

02 모델 성능 향상: LSTM(시계열)과 RESNET(차트)을 결합한 MULTI-MODAL 하이브리드 모델 구축

참고문헌

[1] MEHTAB, S., SEN, J., & DUTTA, A. (2020, OCTOBER). STOCK PRICE PREDICTION USING MACHINE LEARNING AND LSTM-BASED DEEP LEARNING MODELS. IN SYMPOSIUM ON MACHINE LEARNING AND METAHEURISTICS ALGORITHMS, AND APPLICATIONS (PP. 88-106). SINGAPORE: SPRINGER SINGAPORE.
[2] HE, K., ZHANG, X., REN, S., & SUN, J. (2016). DEEP RESIDUAL LEARNING FOR IMAGE RECOGNITION. IN PROCEEDINGS OF THE IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (PP. 770-778).
[3] SEZER, O. B., & OZBAYOGLU, A. M. (2018). ALGORITHMIC FINANCIAL TRADING WITH DEEP CONVOLUTIONAL NEURAL NETWORKS: TIME SERIES TO IMAGE CONVERSION APPROACH. APPLIED SOFT COMPUTING, 70, 525-538.
[4] SEZER, O. B., GUDELEK, M. U., & OZBAYOGLU, A. M. (2020). FINANCIAL TIME SERIES FORECASTING WITH DEEP LEARNING: A SYSTEMATIC LITERATURE REVIEW: 2005-2019. APPLIED SOFT COMPUTING, 90, 106181.

Q&A

감사합니다